



UNIVERSITÉ DE TOULOUSE
DOUBLE LICENCE DE MATHÉMATIQUES ET INFORMATIQUE

Génération d'Échographies Synthétiques par Modèles de Diffusion pour la Segmentation d'Images Réelles

présenté par

BABU Bastien 22302768


Laboratoire d'accueil

Institut de Recherche en Informatique de Toulouse (IRIT)

encadré par

Duong Hung PHAM

réalisé le 14 juin 2026



Première image échographique de l'histoire (1958), par Ian Donald [1].

“Diagnosis is not the end, but the beginning of practice.”

Martin H. Fischer

Remerciements

Je tiens à remercier chaleureusement mon encadrant, Duong Hung PHAM, pour m'avoir proposé ce sujet stimulant et pour ses précieux conseils tout au long de ce projet d'initiation à la recherche.

Je remercie également les enseignants de ma formation, et en particulier Alain Crouzil, membre de l'équipe MINDS à l'IRIT, dont le cours d'Image et Signal m'a fourni les bases théoriques indispensables à la compréhension de ce sujet.

Mes remerciements s'adressent aussi au laboratoire IRIT pour son accueil, ainsi qu'aux responsables de la Double Licence de Mathématiques et Informatique, Milian Poquet et Mathieu Sablik, pour leur accompagnement et leur investissement tout au long de ces trois années de formation.

Enfin, je remercie profondément ma famille et mes proches pour leur soutien et leurs encouragements constants.

Table des matières

I	Introduction	3
II	Contexte et Fondements de l’Imagerie Médicale	4
II.1	L’échographie : Principes physiques et formation de l’image	4
II.1.1	Propagation de l’onde et interaction avec les tissus	4
II.1.2	Diffusion et apparition du "speckle"	4
II.1.3	Formation de l’image	4
II.2	Problèmes Inverses en imagerie médicale	5
II.2.1	Modélisation mathématique du problème	5
II.2.2	Définition d’un problème mathématique mal posé	5
II.2.3	Régularisation et limites des approches classiques	6
II.3	La segmentation d’images médicales : Définition et objectifs	6
II.4	Deep Learning	7
II.4.1	Les Réseaux de Neurones Convolutifs (CNN)	7
II.4.2	L’architecture U-Net et la segmentation sémantique	8
III	Génération Synthétique : De la Théorie à la Méthode de David Stojanovski et al.	10
III.1	Modèles Génératifs et Synthèse d’Images Échographiques	10
III.1.1	Les Réseaux Antagonistes Génératifs (GANs)	10
III.1.2	Les Modèles de Diffusion Probabilistes (DDPM)	11
III.1.3	Bilan : Les limites génératives face aux exigences cliniques	12
III.2	La méthode de Stojanovski et al. : génération guidée par la sémantique	13
III.2.1	Le Modèle de Diffusion Sémantique (SDM) et le mécanisme SPADE	13
III.2.2	Pipeline de la méthode de Stojanovski D. et al.	14
III.2.3	Adaptations algorithmiques du SDM pour l’imagerie médicale	15
III.2.4	Résultats et analyse comparative	15
IV	Conclusion	17
V	Bibliographie	18
VI	Annexes	20
VI.1	Démonstration fréquentielle de l’instabilité du problème inverse	20
VI.2	Détails cliniques et explication des jeux de données CAMUS	21
VI.3	Comparaison visuelle : SDM vs CycleGAN	22

I. Introduction

L'année 1958 marque l'arrivée de la toute première image échographique de l'histoire, réalisée par Ian Donald. Depuis, l'échographie cardiaque est devenue l'examen le plus utilisé en cardiologie car elle est rapide, peu coûteuse, sans danger pour le patient (pas de rayons X) et donne une image du coeur en temps réel. Elle constitue aujourd'hui un outil indispensable pour le diagnostic et le suivi de nombreuses pathologies cardiovasculaires. Selon l'Organisation Mondiale de la Santé (OMS), ces pathologies représentent la première cause de mortalité dans le monde [2], l'accès à un diagnostic rapide et précis est devenu indispensable pour la santé publique.

À ce jour, l'analyse de ces images reste encore un travail manuel. Pour extraire des informations cliniques utiles comme la fraction d'éjection du ventricule gauche, le cardiologue doit délimiter à la main les cavités cardiaques sur chaque image. C'est très long, fastidieux, et deux médecins ne donnent pas toujours le même résultat sur la même image (appelé la variabilité inter-observateurs). L'automatisation de cette étape, via l'intelligence artificielle, constitue donc un enjeu majeur pour améliorer la reproductibilité et l'efficacité de l'analyse échocardiographique.

Le problème, c'est que les réseaux de neurones, c'est-à-dire des modèles d'apprentissage automatique capables de réaliser des tâches complexes, ont besoin de beaucoup de données pour apprendre. En imagerie médicale, ces données sont rares parce qu'elles sont confidentielles, coûteuses à acquérir, et chaque image doit être annotée manuellement par un expert. Contrairement aux photographies classiques où n'importe qui peut identifier un objet, annoter le contour d'un ventricule dans le bruit d'une échographie demande des années d'études médicales. Sans suffisamment d'exemples, le réseau n'apprend pas grand chose, au contraire il finira par mémoriser les cas qu'il a vus plusieurs fois sans savoir s'adapter à de nouveaux patients. Ce phénomène d'*overfitting* (ou surapprentissage) empêche le modèle d'être généralisé et fait de lui un modèle peu fiable, et c'est l'un des problèmes centraux de l'apprentissage profond de manière générale, tout particulièrement en médecine.

Et si on fabriquait les données qui nous manquent ? C'est l'idée de Stojanovski et al. dans leur article [3] : générer des échographies cardiaques synthétiques, suffisamment réalistes pour entraîner un réseau de segmentation, sans avoir besoin d'une seule image réelle annotée. En s'appuyant sur des modèles génératifs capables de recréer artificiellement la texture complexe des ultrasons à partir de masques anatomiques, ils proposent de contourner cette pénurie. L'étude de cette méthode constitue tout l'enjeu de ce stage d'initiation à la recherche (TER).

Ce rapport explore donc le chemin qui mène à cette idée. Dans un premier temps, on commencera par comprendre comment fonctionne une échographie, pourquoi son analyse automatique est difficile et pourquoi on en vient au Deep Learning II. On présentera ensuite les modèles d'IA générative, leurs avantages, ainsi que leurs limites face aux exigences médicales III.1. On finira par détailler la méthode de Stojanovski et al., comment elle fonctionne et les résultats qu'elle permet d'obtenir en pratique III.2.

II. Contexte et Fondements de l’Imagerie Médicale

II.1 L’échographie : Principes physiques et formation de l’image

Afin de pouvoir générer des échographies synthétiques réalistes via l’intelligence artificielle, il est crucial de comprendre comment ces images sont créées physiquement.

II.1.1 Propagation de l’onde et interaction avec les tissus

L’échographie, ou ultrasonographie, est une technique d’imagerie médicale reposant sur l’utilisation d’ultrasons dont les fréquences varient généralement entre 2 et 15 MHz dans le cadre médical. Contrairement à la radiographie ou au scanner qui utilisent des rayonnements ionisants (rayons X), l’échographie exploite les propriétés mécaniques de propagation du son dans les tissus biologiques. En pratique, les ondes sont émises puis reçues par une sonde, appelée transducteur, grâce à des cristaux dits piézoélectriques.

L’onde réagit différemment selon le milieu traversé. On définit l’impédance acoustique, notée Z , comme la "résistance acoustique" de chaque tissu. Nous avons la formule suivante :

$$Z = \rho \cdot c$$

où ρ est la masse volumique du tissu et c la vitesse du son dans ce milieu (en moyenne 1540 m/s dans le corps humain). Lorsque l’onde ultrasonore rencontre la frontière entre deux tissus d’impédances différentes (par exemple entre le muscle et la graisse), une partie de l’onde se réfléchit vers la sonde pour former un écho (utile à l’image), tandis que l’autre partie continue son chemin dans les tissus plus profonds [4].

II.1.2 Diffusion et apparition du "speckle"

Lorsqu’elles rencontrent de très petites structures anatomiques comme des cellules, les ondes émises sont alors dispersées dans plusieurs directions différentes. Il s’agit du phénomène de diffusion (scattering). Ces minuscules échos se superposent avec ceux formant l’image, créant un motif granuleux caractéristique qu’on appelle "speckle". Ce n’est pas qu’un simple bruit mais le reflet des propriétés acoustiques du tissu. Il est important de préciser cela ici, car pour qu’un modèle de diffusion génère une image échographique synthétique crédible, il est nécessaire qu’il apprenne à bien représenter cette texture spécifique et complexe de l’échographie.

II.1.3 Formation de l’image

Pour construire l’image le système utilise le temps de trajet des ondes ultrasonores. En effet, il chronomètre le temps t que met l’écho à revenir vers la sonde afin d’en déduire la distance d de la zone réfléchissante qui se calcule, en tenant compte du trajet aller-retour, par la formule fondamentale :

$$d = \frac{c \cdot t}{2}$$

Enfin, l’intensité de l’écho détermine le niveau de gris du pixel. Cette intensité repose sur le principe suivant :

- Plus l’écho est fort, plus le pixel sera blanc : on parle alors de structure hyperéchogène.
- L’absence d’écho donnera un pixel noir : on parle alors de structure anéchoïque.

Cependant, l’analyse automatisée de l’échographie a posé un défi majeur aux mathématiciens pendant plusieurs années, notamment de par cette nature physiquement bruitée et complexe. Ce défi est connu sous le nom de problème inverse.

II.2 Problèmes Inverses en imagerie médicale

Comme nous l'avons vu, la formation d'une image échographique s'obtient en tenant compte de certaines lois de la physique. En mathématiques appliquées, simuler cette acquisition, c'est-à-dire calculer l'image résultante à partir de l'anatomie connue du patient, correspond à ce qu'on appelle le problème direct.

Cependant, dans le cadre d'une analyse automatisée, c'est-à-dire le fait de confier à un algorithme l'extraction des informations cliniques, comme le détournage des ventricules du coeur, la démarche est strictement opposée. En effet, ce dernier dispose uniquement de l'image bruitée par la sonde et cherche à en déduire l'anatomie exacte du patient. Il doit donc remonter de l'observation vers la cause initiale ce qui constitue ce qu'on appelle un problème inverse.

II.2.1 Modélisation mathématique du problème

Avant de traiter cette famille de problèmes informatiquement nous allons, dans un premier temps, le décrire sous forme d'équation mathématique. En traitement du signal, l'image observée peut être modélisée par :

$$y = H(x) + n$$

où,

- y représente l'image échographique finale (affichée sur l'écran de sortie)
- x représente le signal d'origine pur (l'anatomie réelle et nette que l'on veut isoler)
- H est la fonction de dégradation (opérateur direct) qui modélise la perte de résolution spatiale due aux limites physiques de la sonde, se traduisant par un flou sur l'image
- n représente le bruit additif aléatoire, qui correspond ici au phénomène de "speckle" précédemment détaillé.

Le speckle est généralement modélisé comme un bruit multiplicatif dans les images échographiques brutes, mais il est souvent approximé par un bruit additif après compression logarithmique du signal. [5].

II.2.2 Définition d'un problème mathématique mal posé

D'après ce qui précède, l'objectif de tout algorithme d'analyse d'image serait d'inverser cette équation afin de retrouver x à partir de y . Intuitivement, il serait tentant de penser à une simple inversion algébrique. Toutefois, pour que ce problème mathématique soit considéré comme "bien posé" au sens du mathématicien français Jacques Hadamard [6], il doit respecter les trois conditions suivantes :

- **L'existence** : il existe au moins une solution au problème.
- **L'unicité** : cette solution est unique.
- **La stabilité** : la solution dépend de manière continue des données initiales (une infime variation des données observées ne doit entraîner qu'une infime variation de la solution).

La recherche d'une fonction réciproque H^{-1} pour retrouver l'image pure est instable voire impossible car cela viole le respect de ces conditions, rendant le problème dit "mal posé". D'une part, la condition d'unicité n'est souvent pas respectée car l'opérateur H provoque une perte d'information irréversible (plusieurs images d'origine pourraient produire la même image floutée). D'autre part, c'est la condition de stabilité qui est le plus mise en échec. L'opérateur H agit comme un filtre passe-bas, son inversion se comporte donc comme un amplificateur des hautes fréquences. Le bruit n , riche en hautes fréquences, est fortement amplifié lors de l'inversion, pouvant masquer le signal clinique utile (voir la démonstration en Annexe VI.1) [7].

II.2.3 Régularisation et limites des approches classiques

Afin de contourner cette instabilité, la résolution des problèmes inverses s'est longtemps appuyée sur des méthodes de régularisation. Le but n'est alors plus d'inverser directement l'opérateur H , mais de rechercher une solution approchée du problème inverse. Concrètement, cela revient à formuler un problème d'optimisation : on estime une image compatible avec les données observées, tout en lui imposant certaines contraintes mathématiques (par exemple un lissage destiné à atténuer le bruit). Parmi les méthodes classiques utilisées en imagerie médicale, on retrouve notamment la régularisation de Tikhonov [8], la Variation Totale [9], ou encore les modèles de contours actifs ("Snakes" [10]) [7]. Ces approches interviennent aussi bien dans les tâches de restauration que de segmentation d'images médicales.

Toutefois, ces méthodes montrent leurs limites face à la complexité de l'échographie. Le speckle générant d'innombrables faux gradients, les algorithmes peinent à trouver un compromis robuste entre suppression du bruit et conservation des structures anatomiques importantes. Soit le lissage efface des détails cliniquement pertinents, soit le bruit perturbe fortement la détection des contours. Les limites rencontrées par ces modèles analytiques ont progressivement motivé le recours à des approches statistiques d'apprentissage profond (Deep Learning). Avant d'étudier comment ces architectures répondent à ces difficultés, il convient de définir formellement la tâche informatique et clinique que nous cherchons à automatiser, c'est-à-dire, la segmentation.

II.3 La segmentation d'images médicales : Définition et objectifs

En vision par ordinateur, l'analyse automatisée d'une image nécessite de dépasser sa simple observation globale pour en extraire des entités structurales cohérentes. Formellement, la segmentation se définit comme la partition de l'image en composantes connexes, appelées régions, constituées de pixels partageant une propriété commune. Cette propriété repose généralement sur un critère d'homogénéité lié à l'intensité des niveaux de gris, à la couleur ou à la texture de l'image [11]. Il convient de distinguer fondamentalement cette tâche de la classification d'images. La classification consiste à attribuer une étiquette unique et globale à l'ensemble d'une observation alors que la segmentation opère à l'échelle locale. Elle s'apparente à une classification au niveau du pixel (*pixel-wise classification*), où chaque pixel doit être associé individuellement à une classe sémantique précise (comme le fond, le muscle ou le sang) [12].

En traitement d'images traditionnel, la littérature et les enseignements académiques distinguent principalement trois approches automatiques pour accomplir cette tâche [11] :

- L'approche par les régions, qui analyse les pixels composant les régions selon leur homogénéité.
- L'approche par les contours, qui cible les pixels constituant les frontières entre les régions (les zones de rupture du critère d'homogénéité).
- L'approche par classification directe des pixels, chaque pixel est associé à une classe et les pixels connexes appartenant à une même classe forment une région.

Dans le contexte clinique de ce projet, l'objectif de la segmentation est d'isoler automatiquement les cavités cardiaques gauches et leurs parois. Plus précisément, en s'appuyant sur les standards de bases de données publiques telles que CAMUS VI.2, il s'agit de segmenter trois structures anatomiques : la cavité du ventricule gauche (endocarde), le muscle cardiaque l'entourant (épicaire) et l'oreillette gauche (atrium). Sur une image échographique, cela revient à séparer les structures anéchoïques centrales (le sang dans les cavités) des structures hypoéchogènes périphériques (le muscle). [13].

II.4 Deep Learning

Comme nous l'avons vu dans II.2, les méthodes de régularisation pour résoudre les problèmes inverses sont souvent très limitées dû à la complexité de l'échographie. Pour faire face à ces limites, les chercheurs ont été motivés à utiliser et chercher des méthodes robustes utilisant l'apprentissage profond. Nous allons donc voir comment le Deep Learning s'est imposé en imagerie médicale et pourquoi il représente une solution prometteuse par rapport aux anciennes méthodes de régularisation.

II.4.1 Les Réseaux de Neurones Convolutifs (CNN)

En imagerie, la difficulté principale vient du fait que les images contiennent énormément d'informations avec une cohérence spatiale (par exemple, l'intensité d'un pixel est très liée à celle de ses voisins). Afin d'utiliser un réseau de neurones standard (perceptron multicouche), il faudrait "aplatir" l'image 2D en un immense vecteur 1D. Cela impliquerait une perte de l'information spatiale et de la notion de voisinage. De plus, cela conduirait à un très grand nombre de paramètres à apprendre rendant le modèle inefficace.

C'est pour pallier ce problème qu'en 1998 les réseaux de neurones convolutifs (CNN) ont été popularisés par Yann LeCun et al. avec leurs travaux sur LeNet, dont la version la plus connue, LeNet-5, a été présentée dans [14]. Le fonctionnement d'un CNN repose sur l'idée d'appliquer localement une succession de petits filtres (ou masques) contenant des poids sur l'image d'origine. Ces filtres parcourent l'image dans le but de détecter des motifs précis comme des bords, des variations d'intensité ou des textures. Chaque passage d'un filtre sur l'image produit ce qu'on appelle une "carte de caractéristiques" (*feature map*). C'est une nouvelle matrice cartographiant les zones où le filtre a reconnu le motif cherché. En empilant plusieurs couches de convolution, le réseau devient de plus en plus précis dans la formation des motifs. Les premières cartes de caractéristiques mettent en évidence des motifs très simples (des petits segments), tandis que les cartes plus profondes combinent ces segments pour révéler des structures complexes (comme la paroi complète d'un ventricule).[15]

Mathématiquement, pour une image d'entrée I et un filtre F (aussi appelé masque de convolution), de taille $(2k + 1) \times (2k + 1)$ dont les poids sont optimisés durant l'entraînement, l'opération linéaire de convolution discrète 2D qui génère la carte de caractéristiques S au pixel (i, j) s'écrit :

$$S(i, j) = (I * F)(i, j) = \sum_{m=-k}^k \sum_{n=-k}^k I(i - m, j - n) F(m, n)$$

Les coefficients du filtre ne sont pas définis manuellement. Ils sont optimisés automatiquement au cours de l'entraînement à partir des données disponibles, par une descente de gradient. Cette capacité d'apprentissage constitue l'un des principaux avantages des CNN par rapport aux méthodes classiques reposant sur des filtres fixes.

Cependant, pour qu'un modèle puisse repérer des structures anatomiques complexes (qui ne sont pas de simples lignes droites), il faut introduire des non-linéarités. C'est pour cette raison qu'on a mis en place des fonctions d'activation. Il s'agit simplement de fonctions qui agissent comme un filtre de pertinence, conservant les signaux utiles et annulant les autres pour permettre au réseau de modéliser des courbures et des textures spécifiques aux tissus échographiques. Une des fonctions d'activation les plus utilisées dans les CNN est la ReLU (Rectified Linear Unit), depuis les travaux de Krizhevsky et al. en 2012 [16]. Son fonctionnement est extrêmement simple :

$$f(x) = \max(0, x)$$

Cette fonction ne fait que conserver les valeurs positives et mettre toutes les valeurs négatives à zéro. Ce sont ces cassures qui permettent de créer des non-linéarités et permettant ainsi au réseau de coller à des géométries complexes.

Dans le contexte de l'échographie, les CNN présentent un avantage majeur car les filtres appris s'adaptent directement aux caractéristiques des images d'entraînement. Ils sont ainsi capables d'extraire des informations pertinentes malgré la présence du bruit de speckle et la faible qualité de certaines structures anatomiques. Cette capacité d'adaptation explique pourquoi les CNN sont aujourd'hui devenus la base de nombreuses méthodes modernes d'analyse et de segmentation d'images médicales que nous allons développer par la suite.




FIGURE II.1 – Architecture standard d'un réseau de neurones convolutif (CNN) appliquée à l'imagerie médicale. L'image brute subit une extraction hiérarchique de caractéristiques (*Feature Extraction*) via des couches de convolution et de sous-échantillonnage (*Pooling*). Le tenseur résultant est ensuite aplati (*Flatten Layer*) puis traité par des couches denses (*Fully-Connected Layer*) pour formuler une prédiction finale. Schéma extrait de Rguibi et al. [17].

II.4.2 L'architecture U-Net et la segmentation sémantique

Dans le cadre de l'analyse des échographies cardiaques, l'objectif n'est pas simplement de classer une image, mais d'effectuer une segmentation sémantique, c'est-à-dire de classer chaque pixel pour détacher précisément des structures organiques (le ventricule gauche) comme précisé II.3. Un CNN classique, avec sa succession de convolutions et de Max-Pooling, réduit la taille spatiale de l'image au fil des couches. Ce dernier permet certes de comprendre efficacement le contexte global et ce qu'il y a de représenté sur l'image mais il perd la localisation précise des contours. Pour résoudre cette limite, O.Ronneberger et al. ont introduit en 2015 l'architecture U-Net [18]. Comme son nom l'indique, ce réseau adopte une structure symétrique en forme de « U » divisée en deux grandes parties : un chemin de contraction (*contracting path*) agissant comme un encodeur et un chemin d'expansion (*expanding path*) agissant comme un décodeur.

Comme on peut le constater sur II.2, le chemin contractant (à gauche du « U ») fonctionne comme un CNN classique décrit précédemment II.4.1. Il enchaîne des convolutions (suivies d'une ReLU) et de *Max-Pooling* pour diviser la taille de l'image par deux à chaque étape. Ce processus permet de condenser l'information et de comprendre l'image à un niveau très abstrait. Le chemin expansif (à droite du « U »), réalise l'opération inverse. Son but est de reconstruire une carte de prédiction de la même taille que l'image d'origine. Pour cela, il utilise des convolutions transposées (*up-convolution*) de taille 2×2 qui doublent les dimensions spatiales à chaque étape de la remontée.




FIGURE II.2 – Architecture U-Net (exemple pour des images de 32×32 pixels à la résolution la plus basse). Chaque boîte bleue correspond à une carte de caractéristiques (*feature map*) multi-canaux. Le nombre de canaux est indiqué en haut de la boîte. La taille x,y est donnée dans le coin inférieur gauche de la boîte. Les boîtes blanches représentent des cartes de caractéristiques copiées. Les flèches indiquent les différentes opérations. Schéma extrait de O.Ronneberger et al. [18].

Cependant, si le décodeur remontait seul, il concevrait ses masques à l’aveugle et produirait des contours très flous. L’innovation majeure de l’article de O.Ronneberger réside dans l’introduction des connexions sautées (communément appelé *skip connections*). À chaque niveau de la remontée, les cartes de caractéristiques issues du chemin contractant sont directement copiées et fusionnées avec les cartes du chemin expansif. Ces passerelles fournissent au décodeur les détails géométriques fins et locaux qui avaient été perdus lors du sous-échantillonnage. Il est important de noter que le U-Net réalise une concaténation (il colle les informations côte à côte dans de nouveaux canaux) et non une simple somme mathématique. Si on additionnait bêtement les pixels, les informations floues et abstraites du décodeur viendraient corrompre ou lisser les détails nets de l’encodeur.

Pour qu’un réseau U-Net apprenne à segmenter correctement, il utilise un apprentissage dit supervisé. Cela signifie que pendant sa phase d’entraînement, le réseau a impérativement besoin de paires de données : une image brute associée à son masque parfait (le « corrigé », tracé par un expert). Le programme compare la prédiction du U-Net avec ce masque parfait pour calculer son erreur et ajuster ses poids. Cependant, obtenir ces paires est très difficile. Un intérêt fondamental mis en avant dans l’article officiel est d’ailleurs la capacité du U-Net à être entraîné efficacement à partir de très peu de données annotées. Le modèle s’appuie, en effet, sur l’augmentation de données (*data augmentation*), c’est-à-dire la création artificielle de nouvelles images d’entraînement en appliquant des déformations géométriques ou visuelles aux données existantes. Cette caractéristique est cruciale en imagerie médicale, où les bases de données sont souvent restreintes en raison du coût et de la complexité de l’expertise clinique.

Malgré son efficacité en imagerie médicale, le U-Net présente certaines limites. D’une part, conserver toutes les cartes de l’encodeur en mémoire pour la concaténation consomme énormément de mémoire GPU. De plus, fusionner directement des caractéristiques très brutes avec des caractéristiques très abstraites crée un « fossé sémantique » qui peut rendre l’entraînement difficile. Des variantes ont été proposées pour pallier ces limitations, notamment le U-Net++ [19], dont le principe ne sera pas détaillé ici.

III. Génération Synthétique : De la Théorie à la Méthode de David Stojanovski et al.

Dans le chapitre précédent, nous avons posé les bases théoriques nécessaires à la compréhension de ce chapitre, ainsi qu'un point historique permettant de saisir pourquoi le Deep Learning s'est imposé comme solution. Nous avons également montré que les performances des architectures de segmentation, comme le U-Net, sont extrêmement dépendantes de la quantité de données cliniques annotées disponibles. Afin de faire face à ce problème, ce chapitre explore une autre approche consistant à étudier comment l'intelligence artificielle générative peut permettre de synthétiser de nouvelles échographies réalistes. Nous présenterons d'abord l'évolution des modèles génératifs profonds, puis nous détaillerons la méthode proposée par Stojanovski et al.

III.1 Modèles Génératifs et Synthèse d'Images Échographiques

Comme conclu dans le chapitre précédent, l'entraînement d'architectures de segmentation, similaire au U-Net, s'appuie massivement sur l'augmentation de données pour compenser le manque de données cliniques. Cependant, ces déformations élastiques se limitent à manipuler des coupes existantes. Par conséquent, face à des données inédites, ce qui peut clairement arriver au vu des différences biologique entre les patients, le modèle risque d'échouer. Pour faire face à ce manque de diversité, il est nécessaire de synthétiser des échographies inédites grâce à l'intelligence artificielle générative.

III.1.1 Les Réseaux Antagonistes Génératifs (GANs)

Les Réseaux Antagonistes Génératifs (GANs), introduits en 2014 par Ian J. Goodfellow et al. en 2014 [20], sont souvent considérés comme les précurseurs de l'IA générative en imagerie. Pour en comprendre le fonctionnement, l'article original propose une analogie très intuitive que je propose de réutiliser. Mais avant, il est quand même nécessaire d'établir quelques bases. Le modèle consiste à entraîner en même temps deux réseaux qui vont s'affronter : le Générateur (G) et le Discriminateur D. Le réseau G reçoit en entrée un vecteur aléatoire (issu d'une loi normale ou uniforme), appelé vecteur latent, et apprend à le transformer en une image réaliste. Le réseau D, quant à lui, reçoit des images et doit distinguer les vraies des fausses (produites par G). On peut donc voir G comme un faussaire fabriquant de la fausse monnaie, et D comme la police qui cherche à détecter les faux billets. Ainsi, plus la police (D) s'améliore, plus le faussaire (G) doit aussi améliorer sa technique, et inversement. L'entraînement se termine idéalement lorsque G génère des données tellement réalistes que D n'arrive même plus à faire la différence avec les vrais (il répond au hasard).

Néanmoins, même si il s'agit d'un modèle très populaire, il présente deux défauts majeurs qui freinent son utilisation.

1. **L'instabilité de l'entraînement** : Entraîner un GAN revient à chercher un équilibre parfait entre les deux réseaux (un équilibre de Nash). Or, les techniques classiques de descente de gradient sont conçues pour minimiser une fonction de coût, pas pour équilibrer un jeu entre deux adversaires. L'entraînement a donc souvent du mal à converger.
2. **L'effondrement de mode (*mode collapse*)** : Il s'agit d'un échec fréquent où le générateur trouve un « raccourci » qui trompe le discriminateur à tous les coups. Le réseau D traitant chaque exemple indépendamment, il ne remarque pas que G se contente de produire systématiquement la même image (ou de très légères variantes). La diversité recherchée pour la base de données est alors totalement perdue. [21]

III.1.2 Les Modèles de Diffusion Probabilistes (DDPM)

Les GANs ont certes dominé la génération d'images par apprentissage profond pendant plusieurs années, mais une approche fondamentalement différente a été présentée en 2020 par Jonathan Ho et al. avec les Modèles Probabilistes de Diffusion par Débruitage (DDPMs) [22], qui sont aujourd'hui devenus le standard de la génération d'images par IA. Contrairement à la dynamique compétitive des GANs, les DDPMs reposent sur un cadre probabiliste rigoureux s'appuyant sur des chaînes de Markov et sont inspirés de la thermodynamique hors équilibre.[23] Pour bien comprendre leur fonctionnement, imaginons une goutte d'encre qui tombe dans un verre d'eau. L'encre va alors se diffuser jusqu'à ce que l'eau devienne complètement trouble. Informatiquement, il est facile d'effectuer ce processus qui, en imagerie, s'apparente au fait de bruiteur une image. Cependant, l'idée principale des DDPMs est de pouvoir effectuer le processus inverse à l'aide d'un réseau de neurones, c'est-à-dire repartir de l'eau trouble pour recréer la goutte d'encre initiale. Il y a donc deux processus à traiter dans ce modèle : le processus direct (*Forward Process*), qui ajoute du bruit, et le processus inverse (*Reverse Process*), qui reconstruit l'image.




FIGURE III.1 – Principe général d'un modèle DDPM. Le processus direct (q) ajoute itérativement du bruit gaussien jusqu'à obtenir un bruit blanc à l'étape T . Le processus inverse (p_θ) apprend à débruiter l'image étape par étape pour régénérer une structure propre.[22].

Le processus direct (Forward Process)

Le processus direct, noté q , consiste à prendre une vraie image $\mathbf{x}_0$ et à la dégrader petit à petit par ajout de bruit gaussien. À chaque étape $t \in \{1, \dots, T\}$, ce bruit est contrôlé par un paramètre $\beta_t \in]0, 1[$, et la transition s'écrit :

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) = \mathcal{N}\left(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}\right) \quad (\text{III.1})$$

Une propriété clé est qu'on peut obtenir $\mathbf{x}_t$ directement depuis $\mathbf{x}_0$ sans simuler toutes les étapes intermédiaires. En posant $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ et ϵ un vecteur de bruit gaussien on a :

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I}) \quad (\text{III.2})$$

Dans [22], $T = 1000$ est fixé empiriquement. À cette étape, $\bar{\alpha}_T \approx 0$ et l'image originale est complètement détruite, il ne reste qu'un bruit gaussien pur $\mathcal{N}(0, \mathbf{I})$.

Le processus inverse (Reverse Process)

Le processus inverse, noté p_θ , est l'étape clé du modèle. Il s'agit d'apprendre à inverser le processus direct, c'est-à-dire repartir d'un bruit gaussien pur $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$ pour générer une nouvelle image réaliste $\mathbf{x}_0$. Ce processus est également modélisé comme une chaîne de Markov, mais cette fois les transitions sont apprises par un réseau de neurones (souvent U-Net II.4.2) de paramètres θ :

$$p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \mu_\theta(\mathbf{x}_t, t), \Sigma_\theta(\mathbf{x}_t, t)) \quad (\text{III.3})$$

Dans [22], les auteurs choisissent de fixer $\Sigma_\theta(\mathbf{x}_t, t) = \sigma_t^2 \mathbf{I}$, l'apprentissage de cette variance s'est révélé instable. Le vrai défi est donc d'apprendre la moyenne $\mu_\theta(\mathbf{x}_t, t)$. La contribution majeure de l'article est de montrer que plutôt que d'apprendre μ_θ directement, il est plus efficace de réécrire cette moyenne en fonction du bruit ϵ . En effet, d'après III.2 on sait exprimer $\mathbf{x}_t$ à partir de $\mathbf{x}_0$ et de ϵ , on peut donc substituer cette relation dans l'expression de μ_θ , ce qui donne :

$$\mu_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \alpha_t}} \epsilon_\theta(\mathbf{x}_t, t) \right) \quad (\text{III.4})$$

où $\epsilon_\theta(\mathbf{x}_t, t)$ est la prédiction du bruit ϵ par le réseau. Le problème se réduit donc à apprendre à retrouver le bruit ϵ qui a été ajouté à $\mathbf{x}_0$ pour obtenir $\mathbf{x}_t$. L'objectif de l'entraînement est alors de minimiser l'erreur quadratique moyenne entre le bruit réel ϵ et le bruit prédit par le réseau $\epsilon_\theta(\mathbf{x}_t, t)$:

$$L_{\text{simple}}(\theta) = \mathbb{E}_{t, \mathbf{x}_0, \epsilon} [\|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|^2] \quad (\text{III.5})$$

Une fois entraîné, le modèle peut générer une nouvelle image entièrement à partir de rien : on part d'un bruit pur $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$ et à chaque étape t , le réseau estime le bruit $\epsilon_\theta(\mathbf{x}_t, t)$ présent dans $\mathbf{x}_t$ et le soustrait pour obtenir $\mathbf{x}_{t-1}$, légèrement moins bruité. En répétant cette opération T fois jusqu'à $t = 0$, on obtient une image finale cohérente $\mathbf{x}_0$.

III.1.3 Bilan : Les limites génératives face aux exigences cliniques

Les modèles génératifs offrent une alternative prometteuse au manque de données médicales, mais ils ne répondent pas tous aux exigences strictes de l'imagerie médicale et plus particulièrement de la cardiologie. Le tableau III.1 synthétise leurs caractéristiques respectives.

TABLE III.1 – Comparaison des GANs et des DDPMs selon des critères techniques et cliniques.

Modèle	GANs	DDPMs
<i>Aspects techniques</i>		
Principe	Jeu adversarial entre un générateur et un discriminateur	Débruitage itératif par chaîne de Markov
Stabilité d'entraînement	Fragile : recherche d'un équilibre de Nash	Robuste : minimisation d'une erreur quadratique moyenne
Diversité des sorties	Faible : risque de <i>mode collapse</i>	Bonne couverture de la distribution apprise
Vitesse d'inférence	Très rapide (un seul passage réseau)	Lente ($T \approx 1000$ étapes de débruitage)
<i>Critères cliniques</i>		
Fiabilité anatomique	Peut produire des structures anatomiquement incohérentes (<i>hallucinations</i>)	Distribution apprise rigoureusement sur les données réelles
Contrôle sémantique	Absent pour cette version	Absent pour cette version
Utilisabilité pour l'augmentation de données médicales	Risqué : diversité et fiabilité insuffisantes	Prometteur mais non contrôlable anatomiquement

Comme le montre le tableau, ces modèles ont un défaut très problématique : la génération à "l'aveugle". Les GANs produisent des hallucinations anatomiques (fusions de parois, effondrement des ventricules), ce qui est inacceptable en médecine où le droit à l'erreur n'existe pas.

Un DDPM classique est certes très réaliste et puissant, mais il génère une échographie aléatoire sans fournir le masque de segmentation correspondant. Or, le réseau U-Net a impérativement besoin de ces paires exactes (image et masque) pour s'entraîner en apprentissage supervisé. Il fallait donc trouver une solution capable de conserver la puissance et la stabilité des DDPMs, tout en forçant l'IA à respecter une anatomie stricte pour générer ces paires.

III.2 La méthode de Stojanovski et al. : génération guidée par la sémantique

D'après ce qui précède, nous disposons désormais d'un modèle de segmentation (U-Net II.4.2), et d'un modèle de génération d'images synthétiques (DDPM) III.1.2. Il ne reste donc plus qu'à lier les deux afin de répondre au problème posé. L'enjeu est donc de modifier le DDPM pour y intégrer ce guidage. C'est ce que proposent Zhou et al. dans [24] avec les Modèles de Diffusion Sémantiques (SDM), une extension du DDPM conditionnée par une carte sémantique. Stojanovski et al. (2023) s'appuient ensuite sur cette architecture dans [3] pour construire une pipeline complète.

III.2.1 Le Modèle de Diffusion Sémantique (SDM) et le mécanisme SPADE

Le Modèle de Diffusion Sémantique (SDM), introduit par Zhou et al. [24], est une extension conditionnelle des DDPMs conçue spécifiquement pour guider la génération d'images à partir d'une carte sémantique $\mathbf{x}$. Dans notre contexte, cette carte représente le masque anatomique où chaque région est labélisée (ventricule gauche, myocarde, atrium).




FIGURE III.2 – Architecture du réseau de débruitage conditionnel SDM. L'image bruitée y_t traverse l'encodeur, tandis que la carte sémantique x est injectée indépendamment à chaque niveau du décodeur via des blocs SPADE pour guider précisément la reconstruction. Schéma adapté de Zhou et al. [24].

Comme l'illustre la Figure III.2, la spécificité du SDM réside dans le traitement séparé de l'image bruitée y_t et de la condition sémantique x . Dans les modèles conditionnels traditionnels, la simple concaténation du masque et de l'image en entrée du réseau échoue. En effet, le passage successif à travers les couches de normalisation standards (comme la *Group Normalization*) a tendance à "lessiver" (*wash away*) l'information sémantique, ce qui détruit le contrôle géométrique au fil des couches profondes [24]. Pour contourner ce problème, l'architecture SDM injecte la carte sémantique directement au cœur du décodeur à l'aide de modules de normalisation adaptative spatiale, appelés SPADE (*Spatially-Adaptive Normalization*). Concrètement, après une normalisation s'effectuant sans paramètres, le bloc SPADE applique une transformation affine dont les coefficients d'échelle $\gamma(x)$ et de décalage $\beta(x)$ sont appris par des couches de convolution directement à partir du masque sémantique :

$$f^{i+1} = \gamma^i(x) \cdot \text{Norm}(f^i) + \beta^i(x) \quad (\text{III.6})$$

où f^i représente les activations de la couche courante. Grâce à ce mécanisme, le réseau maintient une parfaite cohérence spatiale à chaque étape du processus inverse. Le modèle ne génère plus

une échographie de manière aléatoire, mais est contraint de synthétiser les textures ultrasonores réalistes tout en respectant les contours de l'anatomie prescrite [24]. C'est avec cette architecture que D. Stojanovski et al. [3] s'appuient pour générer des échographies cardiaques contrôlées, comme nous allons le voir.

III.2.2 Pipeline de la méthode de Stojanovski D. et al.

L'apport de D. Stojanovski et al. (2023) est qu'ils ont réussi à lier les SDM pour la génération d'images échographiques synthétiques [3]. Cette pipeline se déroule en trois phases, illustrées par la figure III.3.




FIGURE III.3 – Pipeline de génération d'images échographiques synthétiques à partir d'un modèle de diffusion sémantique (SDM), destiné à l'entraînement et à l'évaluation d'un modèle de segmentation sur des données réelles. [3].

1. **La phase d'entraînement du SDM (*SDM Training*)** : Dans un premier temps, le modèle de diffusion sémantique est entraîné sur un jeu de données de référence : la base clinique CAMUS (voir Annexe VI.2 pour les détails). À cette étape, le réseau apprend le processus inverse III.1.2, c'est-à-dire à inverser le bruit itératif pour reconstruire une texture échographique réaliste tout en se faisant guider par les contours géométriques des masques cliniques réels x fournis [3].
2. **La phase d'inférence et d'augmentation (*SDM Inference*)** : Une fois le SDM entraîné et ses poids fixés, on ne lui donne plus des masques réels en entrée. On applique d'abord des transformations géométriques (affines et déformations élastiques) sur les masques initiaux pour créer de nouvelles configurations anatomiques inédites (appelées *augmented labels*). Le SDM est ensuite utilisé en mode inférence, il prend ces masques modifiés et génère, à partir d'un bruit pur, la texture ultrasonore correspondante. On obtient donc une quantité massive de nouvelles paires (image synthétique, masque parfait associé) [3].
3. **La phase de segmentation (*Segmentation*)** : Enfin, le jeu de données entièrement synthétique est utilisé pour entraîner un réseau de segmentation U-Net standard. Le réseau peut maintenant apprendre de manière supervisée à prédire les masques à partir des images d'échographie virtuelles. Pour valider la robustesse de cette approche, le U-Net est testé sur un jeu d'images cliniques réelles, n'ayant été utilisé à aucune étape du processus (sans biais possible) [3].

III.2.3 Adaptations algorithmiques du SDM pour l'imagerie médicale

Afin d'adapter le SDM aux contraintes strictes de l'imagerie médicale, Stojanovski et al. y apportent quelques modifications dont :

- **Schéma de bruit (*Cosine noise schedule*)** : Le schéma linéaire d'ajout de bruit a été remplacé par une fonction cosinus, qui ajoute le bruit plus lentement en début de processus. Cela permet de mieux préserver la structure de l'image dans les premières étapes et améliore la stabilité de l'entraînement." [3].
- **Suppression du *classifier-free guidance*** : Cette stratégie améliore certes la qualité sur des images naturelles mais son retrait lors de l'inférence sur des échographies n'entraîne qu'une très faible perte de qualité. En échange, cela a permis approximativement de diviser le temps de calcul par deux, un gain de vitesse assez précieux lorsque l'on manipule des milliers d'images synthétiques [3].

III.2.4 Résultats et analyse comparative

Dans la figure III.4 on peut observer que les images produites sont très réalistes et convaincantes. On retrouve la texture granuleuse caractéristique du speckle échographique, le cône sombre typique du secteur ultrasonore, et surtout des cavités cardiaques dont les contours correspondent précisément aux masques d'entrée. Ces images sont étudiées selon quatre configurations différentes : En vue 4 et 2 chambres et en fin de diastole ou de systole (Voir annexe concernant le cycle cardiaque VI.2).




FIGURE III.4 – Exemples d'images synthétiques générées par le SDM. A) Images synthétiques seules. B) Images avec le masque superposé. C) Images avec les contours du masque. [3].

Des résultats quantitatifs sont présentés dans le tableau III.2. La métrique utilisée est le *Dice score*, qui est un pourcentage de 0 à 100 qui mesure le chevauchement entre le masque prédit par l'IA et le masque réel. Il est défini par la formule suivante :

$$Dice(P, G) = \frac{2|P \cap G|}{|P| + |G|} \quad (III.7)$$

où, $|P|$ correspond à l'aire totale de la zone prédite par le modèle ; $|G|$ correspond à l'aire totale de la zone définie par la vérité et $|P \cap G|$ représente l'aire de l'intersection entre la prédiction et la vérité. Si $Dice(P, G) = 100$ (ou 1) on parle de segmentation parfaite.

TABLE III.2 – Scores Dice (%) obtenus sur le jeu de test CAMUS (50 patients réels). LVendo (resp. LVepi) : endocarde (resp. épicarde) du ventricule gauche. LA : oreillette gauche. [3]

Données d’entraînement	LVendo	LVepi	LA	Moyenne
SDM 4 chambres ED	91.3 ± 4.4	94.0 ± 3.2	82.6 ± 16.9	89.3 ± 4.9
SDM 4 chambres ES	87.8 ± 5.5	92.7 ± 2.7	88.0 ± 5.3	89.5 ± 2.3
SDM 2 chambres ED	88.0 ± 4.9	89.3 ± 5.5	77.5 ± 16.8	85.0 ± 5.3
SDM 2 chambres ES	87.0 ± 5.7	92.9 ± 2.4	87.9 ± 7.3	89.3 ± 2.6
Tous SDM (combiné)	88.6 ± 5.8	91.9 ± 4.2	85.2 ± 13.2	88.6 ± 2.7
CycleGAN	79.4 ± 9.9	88.6 ± 5.4	71.3 ± 23.7	79.7 ± 7.1
Vraies données CAMUS	87.8 ± 6.8	90.9 ± 5.4	82.6 ± 14.4	87.1 ± 3.4

Dans ce tableau Stojanovski et al. comparent leur méthode à celle du *CycleGAN* présenté dans [25]. Le CycleGAN est une architecture issue des GANs conçue pour la traduction d’image à image. Bien que capable de transformer un masque en échographie, ce modèle hérite des faiblesses structurelles des GANs III.1.1.

Plusieurs observations intéressantes ressortent de ce tableau. Premièrement, le modèle de Stojanovski et al. entraîné uniquement sur des données synthétiques dépasse le CycleGAN sur toutes les structures, avec un écart particulièrement marqué sur l’oreillette gauche (+13.9% de Dice). Cela confirme que les hallucinations anatomiques du CycleGAN dégradent la qualité des données synthétiques (voir l’image en Annexe VI.3). Deuxièmement, c’est assez frappant mais le modèle de Stojanovski et al. entraîné sur des données entièrement synthétiques fait mieux que celui entraîné sur les vraies données CAMUS (88.6% contre 87.1% en moyenne). Cela peut sembler contre-intuitif, mais ça s’explique par la diversité des paires générées. Grâce aux augmentations géométriques appliquées aux masques, le SDM produit des configurations anatomiques que les 400 patients réels ne couvrent pas forcément. Le modèle de segmentation a donc une variété d’apprentissage plus grande, il est donc plus complet. Enfin, on note que l’écart-type (les valeurs à droite des $\pm$) est réduit pour toutes les structures par rapport au CycleGAN. Cela se remarque notamment sur l’oreille gauche (LA) on a : ± 13.2 (SDM) contre ± 23.7 (CycleGAN) ce qui indique que les performances sont plus stables d’un patient à l’autre. En médecine, c’est très important, ce n’est pas parce qu’un modèle est excellent en moyenne mais échoue qu’il est forcément fiable. On regarde beaucoup l’écart-type afin de juger s’il est sensible à la diversité ou non. On préfère un modèle un peu moins performant en moyenne mais avec un écart-type plus faible plutôt que l’inverse.

Au-delà des chiffres, cette méthode constitue une approche prometteuse. Il devient désormais possible d’entraîner un modèle de segmentation performant sans avoir accès à une seule image réelle annotée par un médecin. Dans un domaine où l’annotation clinique est coûteuse, longue et soumise à la variabilité inter-observateurs (jusqu’à 22% d’écart entre cardiologues expérimentés [3]), c’est une avancée concrète. La méthode ouvre également des perspectives pour des pathologies rares, où il est justement impossible de constituer des bases de données suffisantes. Par exemple, on peut imaginer générer des anatomies pathologiques synthétiques à partir de masques construits manuellement.

IV. Conclusion

En conclusion, ce stage d’initiation à la recherche (TER) avait pour objectif d’étudier et de comprendre la méthode proposée par les chercheurs David Stojanovski et al. dans leur article [3], qui propose de générer des échographies cardiaques synthétiques pour l’entraînement du U-Net ayant pour but la segmentation d’images réelles.

Afin de bien comprendre, nous avons d’abord dû construire un socle de connaissances solide. Nous avons vu comment se forme physiquement une image échographique, pourquoi son analyse automatique constitue un problème inverse difficile, et comment le Deep Learning, et plus particulièrement l’architecture U-Net, est une solution prometteuse pour la segmentation médicale. Nous avons ensuite étudié les modèles génératifs GANS et DDPMs en les expliquant, les comparant afin de voir quels étaient les avantages et les inconvénients de chacun. On a donc pu voir que les GANs ont beaucoup de problèmes d’instabilité et d’hallucinations anatomiques qui sont inacceptables en médecine. Ils présentaient un inconvénient commun, aucun des deux ne pouvait être contrôlé par des cartes sémantiques. Cela est assez problématique notamment si on veut entraîner le réseau de segmentation U-Net qui lui a besoin d’une paire de données en entrée (image synthétique et masque associé) pour s’entraîner. C’est précisément ce verrou que lève le SDM de Zhou et al. [24], en injectant l’information anatomique au coeur du processus de débruitage via le mécanisme SPADE, et que Stojanovski et al. exploitent pour construire la pipeline complète.

Les résultats obtenus sont remarquables, un U-Net entraîné exclusivement sur des données synthétiques atteint 88.6% de Dice score en moyenne sur des images réelles, dépassant à la fois le CycleGAN (79.7%) et même le modèle entraîné sur les vraies données CAMUS (87.1%). Ces chiffres montrent que la synthèse guidée par la sémantique peut constituer une alternative crédible aux données cliniques réelles, ce qui permet des applications dans des domaines où les données sont rares ou difficiles à annoter comme celui de l’imagerie médicale.

Sur le plan personnel, j’ai tenté de faire tourner le pipeline de Stojanovski et al. à partir du code source disponible publiquement sur GitHub [26] afin de reproduire leurs résultats. Le dépôt mentionne une compatibilité CPU, mais à l’examen du code, de nombreuses opérations utilisaient explicitement `.cuda()`, rendant toute exécution sur CPU impossible sans modifier en profondeur un code composé de nombreux fichiers reliés entre eux. J’ai donc tenté l’approche GPU via Google Colab, après avoir résolu des conflits de versions dans le fichier `requirements.txt`, j’ai réussi à mettre en place l’environnement. J’ai alors fait face à un problème de chargement des données CAMUS, je n’ai pas réussi à comprendre l’arborescence attendue par le code pour extraire correctement les données, obtenant à plusieurs reprises l’erreur `Len of dataset: 0`. Cette expérience m’a appris qu’en pratique, réutiliser le code d’un tiers est rarement immédiat et qu’on passe souvent plus de temps sur la configuration que sur la méthode elle-même. C’est à ce stade que j’ai contacté mon encadrant, qui m’a conseillé de me concentrer sur la compréhension théorique et l’analyse du code plutôt qu’à une quelconque reproduction ou implémentation, ce qui correspond pleinement aux objectifs d’une initiation à la recherche.

Plusieurs perspectives prolongent naturellement ce travail. Stojanovski et al. mentionnent eux-mêmes la nécessité d’étendre la méthode à d’autres modalités d’imagerie et d’adresser la variabilité entre appareils et centres cliniques. Plus généralement, on peut imaginer appliquer ce type de pipeline à des pathologies rares pour lesquelles il est impossible de constituer une base de données suffisante. On peut générer des anatomies pathologiques synthétiques à partir de masques construits manuellement afin d’entraîner des modèles de diagnostic là où aucune donnée n’existe aujourd’hui.

V. Bibliographie

- [1] Ian Donald, J Macvicar, and T.G Brown. Investigation of abdominal masses by pulsed ultrasound. *The Lancet*, 271(7032) :1188–1195, 1958. Originally published as Volume 1, Issue 7032.
- [2] World Health Organization. Cardiovascular diseases (cvds) - fact sheet. [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)), 2024. Accessed : 2026-06-14.
- [3] David Stojanovski, Uxio Hermida, Pablo Lamata, Arian Beqiri, and Alberto Gomez. Echo from noise : synthetic ultrasound image generation using diffusion models for real image segmentation, 2023.
- [4] Jean-Philippe Dillenseger. Bases physiques de l'échographie et du mode Doppler. In Paul Legmann and Patricia Bonnin-Fayet, editors, *Guide pratique d'échographie*, chapter I. Elsevier Masson, 6 edition, 2023.
- [5] Anparasy Sivaanpu, Kumaradevan Punithakumar, Rui Zheng, Kim-Cuong T. Nguyen, Michelle Noga, Dean Ta, Edmond H.M. Lou, and Lawrence H. Le. Speckle noise reduction techniques in ultrasound imaging : A comprehensive review of the last two decades (2005–2024). *Computer Methods and Programs in Biomedicine*, 274 :109150, 2026.
- [6] J. Hadamard. Sur les problèmes aux dérivés partielles et leur signification physique. *Princeton University Bulletin*, 13 :49–52, 1902.
- [7] Laure Blanc-Féraud. *Sur quelques problèmes inverses en traitement d'image*. Mémoire d'habilitation à diriger des recherches, Université de Nice-Sophia Antipolis, 2000.
- [8] Andrey N. Tikhonov and Vasilii Y. Arsenin. *Solutions of ill-posed problems*. V. H. Winston & Sons, Washington, D.C. : John Wiley & Sons, New York, 1977. Translated from the Russian, Preface by translation editor Fritz John, Scripta Series in Mathematics.
- [9] Leonid I. Rudin, Stanley Osher, and Emad Fatemi. Nonlinear total variation based noise removal algorithms. *Physica D : Nonlinear Phenomena*, 60(1) :259–268, 1992.
- [10] Michael Kass, Andrew Witkin, and Demetri Terzopoulos. Snakes : Active contour models. *International Journal of Computer Vision*, 1(4) :321–331, 1988.
- [11] Alain Crouzil. Traitement et analyse d'images : Segmentation des images. Support de cours, partie "Traitement et analyse d'images" de l'UE Image & Signal, Université de Toulouse - Paul Sabatier.
- [12] Dzung L Pham, Chenyang Xu, and Jerry L Prince. Current methods in medical image segmentation. *Annual review of biomedical engineering*, 2(1) :315–337, 2000.
- [13] Sarah Leclerc, Erik Smistad, Joao Pedrosa, Andreas Östvik, Frederic Cervenansky, Florian Espinosa, Thomas Espinasse, Thomas Mutnel, Torvald Fife, Frederic Schnell, et al. Deep learning for segmentation using an open large-scale dataset in 2d echocardiography. *IEEE transactions on medical imaging*, 38(9) :2198–2210, 2019.
- [14] Yann Lecun, Patrick Haffner, and Leon Bottou. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86 :2278 – 2324, 12 1998.
- [15] AI Mind. Convolutional neural networks explained : A hands-on guide, 2023.
- [16] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In F. Pereira, C.J. Burges, L. Bottou, and K. Weinberger, editors, *Advances in Neural Information Processing Systems*, volume 25. Curran Associates, Inc., 2012.

- [17] Zakaria Rguibi, Abdelmajid Hajami, Dya Zitouni, Amine Elqaraoui, and Anas Bedraoui. Cxai : Explaining convolutional neural networks for medical imaging diagnostic. *Electronics*, 11(11), 2022.
- [18] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net : Convolutional networks for biomedical image segmentation. *CoRR*, abs/1505.04597, 2015.
- [19] Zongwei Zhou, Md Mahfuzur Rahman Siddiquee, Nima Tajbakhsh, and Jianming Liang. Unet++ : A nested u-net architecture for medical image segmentation. *CoRR*, abs/1807.10165, 2018.
- [20] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial networks, 2014.
- [21] Tim Salimans, Ian J. Goodfellow, Wojciech Zaremba, Vicki Cheung, Alec Radford, and Xi Chen. Improved techniques for training gans. *CoRR*, abs/1606.03498, 2016.
- [22] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *CoRR*, abs/2006.11239, 2020.
- [23] Jascha Sohl-Dickstein, Eric A. Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics, 2015.
- [24] Wengang Zhou, Weilun Wang, Jianmin Bao, Dongdong Chen, Dong Chen, Lu Yuan, and Houqiang Li. Semantic image synthesis via diffusion models, 2026.
- [25] Jun-Yan Zhu, Taesung Park, Phillip Isola, and Alexei A. Efros. Unpaired image-to-image translation using cycle-consistent adversarial networks, 2020.
- [26] David Stojanovski. echo_from_noise : Code to implement “echo from noise : Synthetic ultrasound image generation using diffusion models for real image segmentation”. https://github.com/david-stojanovski/echo_from_noise, 2023.
- [27] Google. Gemini. <https://gemini.google.com>, 2026. Modèle de langage génératif utilisé comme aide rédactionnelle.
- [28] Adrian Basarab. *Quelques problèmes inverses en imagerie ultrasonore*. Habilitation à diriger des recherches, Université Paul Sabatier, Toulouse, France, novembre 2016.
- [29] Rafael C. Gonzalez and Richard E. Woods. *Digital Image Processing*. Pearson, 4th edition, 2018. Chapitre 5 : Image Restoration and Reconstruction.

VI. Annexes

VI.1 Démonstration fréquentielle de l'instabilité du problème inverse

Cette démonstration s'appuie sur la théorie fondamentale du filtrage inverse, formalisée dans les ouvrages de référence en traitement d'images [29]. Dans la section dédiée à la définition du problème mal posé, nous avons défini le modèle d'observation linéaire suivant :

$$y(u, v) = H(x(u, v)) + n(u, v)$$

où (u, v) représentent les coordonnées spatiales de l'image, et l'opérateur H modélise le flou de la dégradation physique de la sonde échographique. En traitement du signal, l'application de cet opérateur linéaire équivaut à une convolution entre l'image pure x et la réponse impulsionnelle h du système. L'équation complète, incluant le bruit additif, s'écrit alors :

$$y(u, v) = (h * x)(u, v) + n(u, v)$$

Pour démontrer formellement la violation de la condition de stabilité de Hadamard lors de l'inversion, il convient d'étudier ce modèle dans le domaine fréquentiel. Pour ce faire, il suffit d'appliquer la Transformée de Fourier (TF). L'opération de convolution spatiale devient alors une simple multiplication :

$$Y(f_u, f_v) = H(f_u, f_v)X(f_u, f_v) + N(f_u, f_v)$$

où (f_u, f_v) désignent les fréquences spatiales de l'image (représentant la rapidité de variation des niveaux de gris, c'est-à-dire les détails fins), et les lettres majuscules désignent la Transformée de Fourier des signaux correspondants.

La résolution algébrique directe (la recherche de l'opérateur inverse H^{-1}) consiste mathématiquement à isoler le signal d'origine $X(f_u, f_v)$ en divisant l'observation par la réponse fréquentielle du flou $H(f_u, f_v)$:

$$X_{estim}(f_u, f_v) = \frac{Y(f_u, f_v)}{H(f_u, f_v)} = X(f_u, f_v) + \frac{N(f_u, f_v)}{H(f_u, f_v)}$$

On peut voir l'instabilité du problème en regardant le terme d'erreur $\frac{N(f_u, f_v)}{H(f_u, f_v)}$. Comme le flou h a pour effet de lisser l'image, il se comporte comme un filtre passe-bas. Mathématiquement, cela veut dire que le module de $H(f_u, f_v)$ tend vers zéro pour les hautes fréquences (quand on regarde les détails fins).

Au contraire, le bruit n (le speckle) contient beaucoup de hautes fréquences. Donc, pour des valeurs de fréquences élevées, on se retrouve à diviser $N(f_u, f_v)$ par un dénominateur $H(f_u, f_v)$ qui est très proche de zéro. Ce quotient va alors tendre vers l'infini et complètement masquer la vraie solution $X(f_u, f_v)$ que l'on cherche à retrouver. Une toute petite perturbation au départ (le bruit) entraîne donc une erreur énorme sur le résultat final calculé : la condition de stabilité n'est pas vérifiée.

VI.2 Détails cliniques et explication des jeux de données CAMUS

Cette annexe explicite les notions cardiologiques et les jeux de données issues de la base CAMUS [3], nécessaires à la bonne compréhension des résultats d'évaluation.

Le cycle cardiaque : Diastole et Systole

Le cœur fonctionne comme une pompe musculaire alternant continuellement entre deux phases majeures :

- **La Diastole (Remplissage)** : C'est la phase de repos du cœur. Le muscle cardiaque se relâche et les cavités se remplissent de sang. On retient comme instant repère la fin de diastole (*End-Diastole*, ED dans [3]) : c'est le moment où le ventricule gauche est au maximum de son volume, juste avant de commencer à se contracter pour expulser le sang.
- **La Systole (Contraction)** : C'est la phase active du cœur. Le muscle se contracte et expulse le sang vers le reste du corps. On retient comme instant repère la fin de systole (*End-Systole*, ES dans [3]) : c'est le moment où le ventricule gauche est au minimum de son volume, il vient de finir d'expulser le sang et va commencer à se remplir à nouveau.

Les vues échocardiographiques

L'acquisition ultrasonore standard explore le cœur sous différents angles, appelés "vues", afin d'obtenir une vue complète des structures cardiaques :

- **Vue 4 cavités (4C / 4 Chamber)** : Coupe permettant d'observer simultanément les quatre cavités du cœur (oreillette gauche, ventricule gauche, oreillette droite, ventricule droit).
- **Vue 2 cavités (2C / 2 Chamber)** : Coupe centrée spécifiquement sur le côté gauche (oreillette gauche et ventricule gauche).

Structure et augmentation du jeu de données

La base CAMUS contient les acquisitions de 500 patients réels. Parmi les 500, 50 servent uniquement pour le test final de segmentation. Sur les 450 restants (400 pour l'entraînement, 50 pour la validation), seules les vues en fin de diastole (ED) ont été utilisées pour entraîner les modèles de diffusion (SDM). Cependant, pour générer le jeu de données synthétique final, les masques des quatre configurations (vues 2C et 4C, aux instants ED et ES) de ces 450 patients ont été exploités. Pour augmenter la diversité, cinq transformations géométriques aléatoires (déformations affines et élastiques) ont été appliquées sur chaque masque, ce qui porte le jeu de données à 9000 masques au total (8000 pour l'entraînement, 1000 pour la validation). Ce sont ces masques augmentés qui sont ensuite fournis au SDM en mode inférence pour générer les 9000 échographies synthétiques correspondantes pour finalement entraîner le réseau de segmentation U-Net. [3].

VI.3 Comparaison visuelle : SDM vs CycleGAN




FIGURE VI.1 – Comparaison des images générées par le SDM et le CycleGAN pour trois masques d'entrée différents. Ligne du haut : images synthétiques générées. Ligne du bas : images avec le masque superposé. Les flèches rouges pointent les erreurs anatomiques du CycleGAN (parois fusionnées, ventricule effondré...). Les flèches vertes montrent que le SDM reproduit correctement ces mêmes structures. [3].