

Génération d'échographies synthétiques par modèles de diffusion pour la segmentation d'images réelles

Réalisé par : BABU Bastien

Encadré par : Duong Hung PHAM

Soutenance — jeudi 18 juin 2026

Institut de Recherche en Informatique de Toulouse (IRIT)

Université de Toulouse — Double Licence Mathématiques & Informatique

L'échocardiographie :

- Examen **le plus utilisé** en cardiologie : rapide, non-invasif, sans rayons X.
- Pathologies cardiovasculaires : **1^{re} cause de mortalité mondiale** (OMS)
- Analyse encore **manuelle** aujourd'hui : délimitation à la main des cavités
 - Très long
 - Fastidieux
 - Variabilité inter-observateurs jusqu'à **22%** entre cardiologues experts

Solution : avoir recours à l'intelligence artificielle pour segmenter les images => gain de temps, reproductibilité.

Besoins du Deep Learning

- Avoir beaucoup de données pour un entraînement et des résultats qualitatifs


Problème ici :

- Manque considérable de données pour utiliser le Deep Learning
 - Confidentialité
 - Coût
 - Nécessite de l'expertise médicale
- Risque d'overfitting (surapprentissage)

L'idée centrale

Et si on **fabriquait** les données manquantes ? Idée de D. Stojanovski et al. pour contourner la pénurie de données cliniques grâce au modèle génératif.



1. **Segmentation - Architecture U-Net (O.Ronneberger et al.)**
2. **Génération - DDPMs (J. Ho et al.) et SDMs (Zhou et al.)**
3. **Pipeline de la méthode de D. Stojanovski et al.**
4. **Résultats et comparaison**
5. **Difficultés rencontrées**



- **Standard de la segmentation médicale**
- **Structure en "U" : encodeur + décodeur**
- **Skip-connections** : les détails fins de l'encodeur sont transmis au décodeur par **concaténation**.
- **Apprentissage supervisé** : besoin de paires (image brute, masque annoté) pour l'entraînement.

⇒ **L'objectif** : Entraîner ce réseau avec une base de données 100% synthétique.

1. Segmentation - Architecture U-Net




Pourquoi ne pas utiliser les GANs (Ian J. Goodfellow et al.)


- **Instabilité de l'entraînement** : besoin de trouver un équilibre de Nash
- **Mode collapse** : production de la même image par le générateur sans que le discriminateur le remarque (traitement indépendant) => pas de diversité
- **Hallucinations anatomiques** : inacceptables en médecine (fusions de parois, effondrement des ventricules)

Modèles de Diffusion Standard (DDPMs - J. Ho et al.)

- **Principe** : Processus de Markov ajoutant du bruit gaussien, puis apprentissage du débruitage inverse.
 - **Processus direct** : ajout de bruit à l'image initiale (x_0).
 - **Processus inverse** : apprend à débruiter l'image pour en retrouver une structure propre.




- **Objectif** : l'entraînement doit minimiser l'erreur quadratique moyenne (entre le bruit réel et prédit)
- **Limite** : Aucun contrôle précis sur la géométrie de l'image générée (Pas de contrôle sémantique).




Mécanique de l'architecture :

- **Encodeur (bleu)** : Comprime l'image bruitée "à l'aveugle" (sans le masque).
- **Décodeur (orange et vert)** : Reconstitue l'image progressivement.
- **Le rôle du Masque (SPADE)** : Injecté de force à chaque bloc du décodeur → le réseau est obligé de respecter l'anatomie à chaque étape.
- **Sortie** : Le réseau estime le bruit à soustraire — on répète T fois jusqu'à obtenir l'échographie finale.



1. **Apprentissage** : reproduction réaliste d'échocardiographie avec guidage sémantique (labels).
2. **Inférence** : création de nouveaux "patients virtuels" par application de déformations géométriques + génération en fonction.
3. **Segmentation** : on fournit au U-Net les paires (image synthétique, masque parfait associé) et on le laisse segmenter.



A) : images synthétiques seules

B) : images avec le masque superposé

C) : images avec les contours du masque

Dice Score en % obtenus sur un jeu de tests CAMUS de 50 patients réels

Données	LVendo	LVepi	LA	Moy.
SDM (tous)	88.6 ± 5.8	91.9 ± 4.2	85.2 ± 13.2	88.6 ± 2.7
Vraies (CAMUS)	87.8 ± 6.8	90.9 ± 5.4	82.6 ± 14.4	87.1 ± 3.4
CycleGAN	79.4 ± 9.9	88.6 ± 5.4	71.3 ± 23.7	79.7 ± 7.1

LVendo = endocarde, LVepi = épicarde, LA = oreillette gauche

Limites :

- **Domain shift** : entraînement uniquement sur la base CAMUS, provenant d'1 hôpital et 1 appareil.
- Généralisation aux **pathologies rares** non prouvée.
- Modèle **très gourmand** en temps de calcul et ressources GPU

La reproductibilité du modèle :

- Incompatibilité locale CPU => nécessité d'avoir un GPU
- Conflits de versions (`requirements.txt`).
- Problèmes d'extraction des données CAMUS (erreur `Len of dataset: 0`).

Déroulement du stage :

- Synthétisation
- Compréhension
- Temps

Bilan de la méthode

- DDPM + SPADE = SDM : génération **réaliste et anatomiquement contrôlée**
- Entraîner un segmenteur performant **sans aucune image réelle annotée**
- Perspectives : pathologies rares, multi-centres, multi-modalités...

Ce que ce stage m'a apporté

- Une immersion concrète dans la **recherche scientifique** : lire, comprendre et critiquer un article
- Découvrir comment la recherche en imagerie médicale et Deep Learning a avancé et va avancer
- Ce stage confirme mon intérêt à poursuivre en imagerie/imagerie médicale



D. Stojanovski et al. (2023).

Echo from noise: synthetic ultrasound image generation using diffusion models for real image segmentation.



W. Zhou et al. (2026).

Semantic Image Synthesis via Diffusion Models.



J. Ho, A. Jain, P. Abbeel (2020).

Denoising Diffusion Probabilistic Models.



O. Ronneberger, P. Fischer, T. Brox (2015).

U-Net: Convolutional Networks for Biomedical Image Segmentation.



I. J. Goodfellow et al. (2014).

Generative Adversarial Networks.



Y. LeCun, P. Haffner, L. Bottou (1998).

Gradient-Based Learning Applied to Document Recognition (Architectures CNN).

Merci pour votre attention !

Avez-vous des questions ?